

Detección de Fraude con Tarjetas de Crédito

Machine learning con validación temporal y métricas operativas de la industria · Python, scikit-learn, pandas


Resumen

Sistema de detección de fraude con tarjeta de extremo a extremo. Un simulador genera una red realista de clientes y terminales e inyecta tres escenarios de fraude (anomalías de monto, terminales comprometidas y robo de datos de tarjeta). Sobre esos datos se construyen variables de comportamiento tipo RFM y un score de riesgo por terminal **desplazado 7 días** — reproduciendo que en producción las etiquetas de fraude llegan tarde — y se entrenan tres clasificadores con partición temporal estricta (entrenamiento / brecha / prueba) que impide fugas de información.


Resultados (periodo de prueba)

Datos: **216,878 transacciones**, **1.065% fraudulentas** — el desbalance real del problema. Con 1% de positivos, el ROC-AUC engaña; la métrica decisiva es Average Precision y la operativa es Card Precision@20: de las 20 tarjetas que un equipo antifraude puede revisar al día, cuántas eran fraude real.

Modelo	ROC-AUC	Average Precision	Card Precision@20
logistic regression	0.898	0.455	0.442
random forest	0.851	0.437	0.390
hist gradient boosting	0.901	0.607	0.517



Curvas Precisión-Recall en el periodo de prueba: el gradient boosting duplica la precisión de la línea base en casi todos los niveles de recall.



Volumen diario de transacciones y fraude del dataset simulado.

Aplicación real

Bancos, fintechs y pasarelas de pago usan exactamente esta arquitectura para priorizar alertas con presupuesto limitado de analistas. La misma técnica (agregados de ventana + retraso de etiquetas + precisión@k) aplica a detección de contracargos en e-commerce, abuso de promociones y cuentas falsas. Todo el pipeline es reproducible con un comando y 11 pruebas automatizadas validan simulador, features y métricas.