

Predicción de Supervivencia — Titanic sin Fuga de Datos

Pipelines de scikit-learn con validación honesta · ColumnTransformer, validación cruzada


Resumen

El benchmark clásico, resuelto con la disciplina que la mayoría omite: **cero fuga de datos**. Todas las estadísticas aprendidas (medianas de imputación, escalado, categorías one-hot) viven dentro del pipeline y se ajustan por fold de validación cruzada. La ingeniería de variables usa conocimiento de dominio: título social extraído del nombre (Mr/Mrs/Master/Officer/Royalty), tamaño de familia y cubierta del camarote.


Resultados (891 pasajeros, 38.4% de supervivencia)

Modelo	Accuracy (CV 5-fold)	ROC-AUC (CV)	F1 (CV)
logistic regression	0.819 ± 0.024	0.866	0.761
random forest	0.823 ± 0.030	0.871	0.750
gradient boosting	0.822 ± 0.035	0.876	0.755

Evaluación final en retención del 20% jamás tocado: **accuracy 0.804, ROC-AUC 0.839, F1 0.733** — consistente con la validación cruzada, es decir, sin sesgo optimista: el número que se reporta es el que se obtendría en producción.



Tasas de supervivencia por sexo, clase y título social — las tres variables más informativas.



Matriz de confusión del mejor modelo en el conjunto de retención.

Aplicación real

La estructura de este proyecto es la plantilla de cualquier problema tabular de negocio: predicción de churn de clientes, scoring de riesgo crediticio, conversión de leads o abandono de carrito. Lo que se transfiere no es el dataset — es la disciplina: pipelines sin fuga, validación honesta y features con conocimiento del dominio.